

Análisis Predictivo de Diabetes en Pacientes

Grupo 3: Predicción de Diabetes

Presentado por:
Jhon Sebastián Caviedes Guevara
David Felipe Perdomo Castillo

Facultad De Ingeniería

Ingeniería de Sistemas



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación
y extensión de programas de pregrado, aplicando todos los
requisitos de las normas ISO implementadas en sus sedes
Neiva y Pitalito"




Análisis Inicial del Dataset de Diabetes

Descripción General


- Registros: 768 pacientes.
- Variables: 9 atributos, incluyendo resultados de glucosa, presión arterial, IMC, edad y un indicador de resultado (diabetes).
- Tipos de Datos: Mayormente numéricos (enteros y flotantes), con la variable objetivo siendo binaria (0/1).

Estadísticos Descriptivos Clave

- Glucosa: Media alta, con una desviación estándar considerable, indicando variabilidad.
- Presión Arterial: Rangos normales para la mayoría, pero con algunos valores extremos que podrían ser atípicos.
- IMC (Índice de Masa Corporal): Distribución que sugiere una parte significativa de la población con sobrepeso u obesidad.
- Edad: Amplio rango, influyendo potencialmente en la aparición de la diabetes.



Tratamiento De Valores Faltantes En Glucosa: Análisis Gráfico Y Estadístico




N° embarazadas	0
Prueba de tolerancia oral a la glucosa	300
Presión arterial diastólica	0
Grosor del pliegue cutáneo del tríceps	0
Insulina sérica de 2 horas	0
Índice de masa corporal	0
Función del pedigrí de la diabetes	0
Edad	0
Variable de clase	0

dtype: int64

Se evidenció que la variable de glucosa tenía 300 valores faltantes, mientras que las demás no presentaban ausencias. Se aplicó un manejo para completar los registros y evitar sesgos en el análisis. La gráfica y la tabla confirman que solo esta variable requería corrección.

Impacto De La Imputación En La Distribución De Glucosa




```
dtype: float64
Media después: 120.09
Mediana después: 118.00
```

☒ TABLA COMPARATIVA ANTES vs DESPUÉS

	Antes	Después
Cantidad	468.000000	768.000000
Media	121.423077	120.085938
Mediana	118.000000	118.000000
Desviación estándar	32.533897	25.441098
Mínimo	0.000000	0.000000
Q1 (25%)	99.000000	111.000000
Q2 (50%)	118.000000	118.000000
Q3 (75%)	140.000000	124.000000
Máximo	199.000000	199.000000

La media descendió ligeramente mientras la mediana subió, acercándose entre sí y mostrando mayor simetría en la distribución. La desviación estándar se redujo de 32.6 a 25.4, lo que refleja menor dispersión y mayor homogeneidad en los datos.

Gráfica Del Codo Y Resumen Estadístico




Nº embarazadas	0
Prueba de tolerancia oral a la glucosa	0
Presión arterial diastólica	0
Grosor del pliegue cutáneo del tríceps	0
Incidencia cénica de 2 horas	0
Índice de masa corporal	0
Función del pedigrí de la diabetes	0
Edad	0
Variable de clase	0

dtype: int64

Se aplicó la técnica del codo y se identificó que tres clústeres eran óptimos. La gráfica muestra el punto de inflexión y la tabla confirma que no hay valores faltantes en las variables analizadas.

Distribución De Individuos Por Condición Diabética

Proporción de Individuos por Clase de Diabetes



*** ESTADÍSTICAS DE LA VARIABLE DE CLASE


	Cantidad	Porcentaje (%)
No Diabetes (0)	500	65.104167
Diabetes (1)	268	34.895833
Total de individuos: 768		

El estudio muestra que el 65.1% de los individuos no presenta diabetes y el 34.9% sí la tiene. La tabla confirma estos porcentajes con un total de 768 registros, reflejando la distribución de la población y sirviendo de base para futuros estudios.



Análisis Descriptivo De Variables Numéricas


Histogramas de variables numéricas




Los histogramas muestran la distribución de las variables y la tabla resume sus medidas principales, ofreciendo una visión clara del comportamiento de los datos y posibles patrones relevantes.

Análisis de Winsorización


Boxplot de variables numéricas



Boxplot General con Winsorización (1% - 99%)



Análisis De La Relación Glucosa–imc



```
--- ESTADÍSTICAS DE 'Prueba de tolerancia oral a la glucosa' ---
Prueba de tolerancia oral a la glucosa
count      768.000000
mean       121.678385
ctd        29.500310
min         0.000000
25%        101.000000
50%        120.000000
75%        138.500000
max        199.000000


dtype: float64

--- ESTADÍSTICAS DE 'Índice de masa corporal' ---
Índice de masa corporal
count      768.000000
mean        31.992578
ctd         7.884160
min         0.000000
25%         27.300000
50%         32.000000
75%         36.800000
max         67.100000

dtype: float64
```

Esta visualización permite identificar tendencias entre ambas variables. La tabla estadística complementa el análisis con medidas descriptivas que evidencian la variabilidad y concentración de los datos.

Correlación de variables clínicas



Test de Normalidad

Variable	Estadístico	p-valor
Nº embarazadas	0,9012	p-valor: 0.0000
Prueba de tolerancia oral a la glucosa	0,965	p-valor: 0.0000
Presión arterial diastólica	0,801	p-valor: 0.0000
Grosor del pliegue cutáneo del tríceps	0,8976	p-valor: 0.0000
Insulina sérica de 2 horas	0,7195	p-valor: 0.0000
Índice de masa corporal	0,9378	p-valor: 0.0000
Función del pedigrí de la diabetes	0,8456	p-valor: 0.0000
Edad	0,8788	p-valor: 0.0000
Variable de clase	0,6057	p-valor: 0.0000

Interpretación general:

- Si $p\text{-valor} < 0.05$: se rechaza la normalidad (no es normal).
- Si $p\text{-valor} \geq 0.05$: no se rechaza la normalidad (compatible con normal).
- Si $p\text{-valor} \geq 0.05$: no se rechaza la normalidad.

Se aplicó un test de normalidad para verificar si las variables clínicas siguen una distribución normal. Los resultados muestran que todas presentan p-valores inferiores a 0.05, lo que indica que no cumplen con el supuesto de normalidad.




Pregunta de Investigación

¿Es posible predecir la prueba de tolerancia oral a la glucosa a partir de las variables clínicas del paciente utilizando un modelo de regresión?



Modelo de Predicción



```
*** === ESTADÍSTICAS POR PORCENTAJE (REGRESIÓN LINEAL MÚLTIPLE) ===
```

	Porcentaje	MAE	RMSE	R^2
0	60-40	0.397440	0.437780	0.134742
1	70-30	0.406814	0.449329	0.108163
2	80-20	0.410873	0.457351	0.088948

```
=== MEJOR CONFIGURACIÓN ===
```

Porcentaje	: 60-40
MAE	: 0.3974
RMSE	: 0.4378
R^2	: 0.1347

Se evaluó el modelo de Regresión Lineal Múltiple usando diferentes particiones del conjunto de datos (60-40, 70-30 y 80-20). El mejor desempeño se obtuvo con el porcentaje que presentó el mayor valor de R^2 , indicando una mayor capacidad explicativa del modelo. Esto sugiere que dicho porcentaje logra un mejor equilibrio entre datos de entrenamiento y prueba.